

TEHNIČKI IZVEŠTAJ

Autonomous Vehicle Analyst - AVA

RAG sistem za analizu godišnjih izveštaja kompanija

6.9.2026

Autor: Lazić Veselin

1. Uvod

AVA je veb-zasnovan analitički asistent za pitanja o godišnjim izveštajima javnih kompanija. Sistem je projektovan tako da se svaka tvrdnja može proveriti u odgovarajućem SEC izvoru. Dohvatanje dokaza, generisanje odgovora, računanje, veb-pretraga, memorija i korisnički interfejs imaju jasno razdvojene odgovornosti.

Osnovni tok je:

SEC EDGAR → nepromenjeni HTML → strukturirani blokovi → chunk-ovi i vektori
 → dense/BM25/RRF retrieval → izbor dokaza → grounded generation → validirane citacije
 → bezbedno prikazivanje izvora u AVA interfejsu

Dohvatanje dokaza određuje da li je relevantan izvor pronađen. Generisanje taj dokaz pretvara u odgovor, pri čemu izlaz modela sam po sebi nije dokaz. Kalkulator izvršava proverljivu aritmetiku, veb-pretraga rešava vremenski promenljive upite, a memorija čuva korisnički kontekst, ali ne potvrđuje činjenice o kompanijama. Korisnički interfejs prikazuje rezultat i izvore, ali ne određuje kompaniju, opseg, plan ni citate.

2. SEC korpus

Korpus je ograničen na jedanaest kompanija iz autonomne vožnje i srodnih tehnoloških oblasti: Aptiv, Aurora, Ford, General Motors, Alphabet, Mobileye, NVIDIA, Ouster, Qualcomm, Rivian i Tesla. Ograničenje omogućava kontrolisano poređenje objava, reproduktivne indekse i vrednovanje sa jasno određenim opsegom. Rivian je dodat nakon početne verzije korpusa sa deset kompanija; promena je evidentirana u dokumentaciji.

APTV	Aptiv PLC	2025-12-31	2026-02-06	1.367	528	394	134
AUR	Aurora	2025-12-31	2026-02-11	909	261	227	34
	Innovation						
F	Ford Motor	2025-12-31	2026-02-11	1.713	576	444	132
GM	General Motors	2025-12-31	2026-01-27	1.066	410	286	124
GOOGL	Alphabet	2025-12-31	2026-02-05	1.260	512	345	167
MBLY	Mobileye	2025-12-27	2026-02-12	1.258	462	412	50
NVDA	NVIDIA	2026-01-25	2026-02-25	980	329	273	56
OUST	Ouster	2025-12-31	2026-03-02	1.112	375	315	60
QCOM	Qualcomm	2025-09-28	2025-11-05	830	321	267	54
RIVN	Rivian	2025-12-31	2026-02-12	1.162	411	323	88
TSLA	Tesla	2025-12-31	2026-01-29	945	341	275	66
Ukupno				12.602	4.526	3.561	965

Vrednosti su iz INTERNSHIP_REPORT.md i odgovaraju v19 freeze manifestu. Aktivni filing je poslednji regularni 10-K; 10-K/A nije primarni dokument. Filing se preuzima sa SEC-hosted HTML-a, a metadata sadrži company, ticker, CIK, form, filing date, reporting period, accession number i source_url. Aktivni frozen filings su 2025-10-K, osim NVIDIA 2026-10-K prema data/evaluation/finalization/v19/freeze_manifest.json.

3. Opseg korpusa

Oblast autonomne vožnje obuhvata proizvođače vozila, dobavljače lidara i senzora, proizvođače čipova, softverske kompanije i pružaoce infrastrukture za podatke i veštačku inteligenciju. Zbog toga se u objavama koriste različiti termini, fiskalni periodi, segmentacije i nivoi finansijske detaljnosti. Korpus je odabran kako bi se takve objave analizirale dosledno i uporedivo.

Korpus ne predstavlja celu industriju autonomne vožnje. Njegov ograničeni obim omogućava proverljivost: opseg kompanija, snimak podnesaka, dokazi dobijeni pretragom i oznake za vrednovanje ostaju kontrolisani.

4. Preuzimanje i obrada izvora

src/filings/fetch_data.py poziva SEC company-submissions endpoint, traži prvi tačan normalni 10-K i preuzima primarni HTML dokument iz SEC arhive. Zahteva se deskriptivan SEC_USER_AGENT, a mrežni pozivi imaju timeout. Rezultat je:

data/raw/TICKER/YEAR-10-K.html
data/raw/TICKER/YEAR-10-K.metadata.json

Raw HTML se ne menja i postojeći snapshot se ne prepisuje bez eksplicitnog overwrite. download-latest i process-existing su odvojeni koraci. Kasniji kod proverava da se ticker, CIK, godina, period i form slažu sa metadata zapisom. Hash-evi raw metadata, processed blokova, chunk-ova, embedding manifest-a i evaluation manifest-a su u v19 freeze manifestu. Time je moguće razlikovati promenu parsera od promene ulaznog filing-a.

Relevantni moduli i provere su src/filings/filing_io.py, src/filings/fetch_data.py, src/filings/corpus.py, src/filings/release_state.py, tests/test_corpus.py, tests/test_live_state.py i freeze evaluacija.

5. HTML čišćenje i parsiranje

Autoritativni izvor ove faze je CLEANING_AND_CHUNKING_REPORT_FINAL.md. Čišćenje ne koristi jedan globalni poziv get_text(), jer bi se izgubile granice pasusa, section pripadnost, redosled i relacije ćelija.

U src/filings/dom_processing.py uklanjaju se script, style, noscript, slike/SVG, HTML head, eksplicitno skriveni elementi, ix:hidden i bezbedno prepoznati viewer/navigation sadržaji. Vidljivi Inline XBRL wrapper-i se uklanjaju, ali njihov vidljivi tekst ostaje. Normalizuju se HTML entiteti, \xa0, soft hyphen, zero-width karakteri i višestruki razmaci. Globalno dedupliranje nije uvedeno jer ponovljena rečenica može biti legitimna, a ponovljeno zaglavlje tabele može biti potrebno u nastavku.

src/filings/block_extraction.py obilazi očišćeni DOM po redosledu pojavljivanja. Pretraga stvarnog Item 1 izbegava cover-page i table-of-contents kopije. Naslovi se prepoznaju i kada nisu h1/h2, na primer kroz kratke bold/styled pasuse. Emit-once logika sprečava da tabela bude izdata kao tabela i zatim ponovljena kao pojedinačni pasusi.

Svaki block ima deterministički block_id, ordinal, company/ticker/CIK, filing metadata, section, section_path, content_type, source tag, anchor i SEC URL. JSONL output se validira i upisuje atomski.

Tabele i parsing eksperimenti

Tabela je bila glavni izvor grešaka. SEC HTML često koristi bold td umesto th, prazne alignment kolone, odvojene \$ i brojeve, višeredna zaglavlja i nastavke kroz više fizičkih tabela. Na MBLY pilotu su pronađeni pogrešno tretirani headers (Name | Age | Position), početni balance redovi u header-u, godine protumačene kao kolone, izgubljeni naslovi RSU/debt tabela i jedna pogrešna globalna jedinica za tabelu sa novcem i procentima.

src/filings/table_processing.py zato prvo čuva fizičke DOM ćelije, koordinate, rowspan/colspan, formatiranje, XPath i HTML fingerprint. Zatim gradi odvojenu logical-table reprezentaciju sa semantic lanes, header paths, row roles, title, region, continuation linkovima, per-column units i raw-cell mapiranjem. Span-aware pravougaona mreža popunjava logičke pozicije; unutrašnje prazne ćelije se čuvaju, dok se samo potpuno prazni redovi/kolone mogu ukloniti.

Prvi verovatni podatkovni red određuje kraj višerednog zaglavlja; četvorocifrena godina sama nije dovoljna za numerički podatak. Tabele se klasifikuju kao data, text, navigation, list ili unknown. Navigation tabele se čuvaju u processed evidence, ali se ne indeksiraju; nejasne tabele se zadržavaju kako se dokaz ne bi izgubio.

Na korpusu je zabeleženo 1.005 fizičkih HTML fragmenata i 978 logical tables, od kojih 965 ulazi u retrieval, a 13 navigation tabela ne proizvodi chunk. Processed QA beleži 1.005 validnih Markdown renderinga i 183 normalization fallback-a; chunk opseg beleži 182. Ta dva broja nisu ista populacija.

6. Podela na segmente

src/chunking/chunk_documents.py zahteva token-based length_function i čuva tokenizer/reviziju u konfiguraciji. Izabrana politika je:

Strategija	RecursiveCharacterTextSplitter	CLEANING_AND_CHUNKING_REPORT_FINAL.md
Narativna veličina	500 tokena	v19 manifest/chunk config
Konfigurisani overlap	32 tokena	v19 manifest/chunk config
Separators	\n\n, \n, razmak, karakter	chunking report

Tabela	jedna kompletna logical table	chunking report
Recursive splitter prvo pokušava granicu pasusa, zatim reda, reči i karaktera. Narativ se ne meša između section_path vrednosti, a section prefix ulazi u budžet. Za svaki chunk čuvaju se source character i token spanovi, block ID, section, content type i filing metadata. Chunk ID zavisi od konfiguracije; zato postoje odvojene gold mape za 250/500 tokena, a stari character baseline ostaje istorijski.		

Benchmark na MBLY i TSLA poređivao je recursive/fixed strategije za 128, 192, 250 i 500 tokena. Sve uspešne konfiguracije imale su 100% coverage blokova, 100% section accuracy i 100% tabelarni kontekst. Na primer, MBLY recursive 500/64 imao je 468 chunk-ova, medianu 253,5 tokena i boundary accuracy 92,1%, naspram fixed 500/64 sa 433 chunk-a i 61,7%. TSLA recursive 500/64 imao je 343 chunk-a i 89,1%, naspram fixed 334 i 66,9%. Recursive 500 je izabran zbog boljih semantičkih granica, iako fixed preciznije ostvaruje nominalni overlap.

Stvarni overlap se meri odvojeno od konfigurisanog overlap-a. Prirodna granica često znači da je izmereni overlap nula; separator-aware algoritam ne garantuje 32 tokena u svakom paru. Tabele su izuzete od narativnog limita: svaka zadržana logička tabela ostaje potpuna u jednom tabelarnom chunk-u, zajedno sa headerima, redovima, jedinicama i izvornim indeksima. Promovisani corpus ima 3.561 narativni i 965 tabelarnih chunk-ova, ukupno 4.526.

Ograničenja: parser radi nad stvarnim HTML <table> elementima, ne zaključuje tabele iz vizuelno poravnatih pasusa, nastavci kroz susedne HTML tabele mogu ostati odvojeni, naslov može biti nepoznat, a page_start/page_end nisu popunjeni.

7. Vektorske reprezentacije

Ekperimenti su uključivali MiniLM i BGE-base; podrška postoji i za druge lokalno odabrane modele kroz src/embeddings/embed_chunks.py. Promovisani embedder je BAAI/bge-base-en-v1.5 sa tačnom revizijom a5beb1e3e68b9ab74eb54cfd186867f64f240e1a.

Dimenzija	768
Normalizacija	da
Query prefix	Represent this sentence for searching relevant passages:
Document prefix	prazan
Manifest	manifest-v3, poravnanje sa chunk redosledom
Korpus	4.526 vektora za 4.526 chunk-ova

Na 300-question benchmarku istorijski MiniLM dense run imao je Recall@10 0,5472 i MRR@10 0,3171. BGE-base v2/v3 je imao Recall@10 0,7072, hit@10 0,7967, complete@10 0,6167 i MRR@10 0,5168. MiniLM je bio brži/jeftiniji za lokalno računanje, ali je BGE imao jasnu retrieval prednost. Svi embedding manifest-i sadrže source hash, model revision, dimenziju, normalizaciju, input truncation informacije i vektorsko poravnanje. Izbor je zato kvalitetno odabran BGE, uz reproduktivni NPZ fallback.

8. Dohvatanje dokaza

Filingski retrieval je implementiran u src/retrieval/dense.py, src/retrieval/opseg_aware.py, src/retrieval/evidence_policy.py i src/indexing/qdrant_index.py. Dense pretraga koristi normalizovane BGE vektore; BM25 je lexical path; hybrid kombinuje rangove reciprocal-rank fusion (RRF). Aktivni v19 parametri su rrf_k=100, candidate_k=50, final_evidence_k=10, minimum dva dostupna chunk-a po subquery-ju i multi-subquery bonus 0,01.

Notebook notebooks/hybrid_rag_generation.ipynb, evaluator src/scripts/evaluate_opseg_aware_hybrid_retrieval.py i deployed API koriste isti opsegaware entry point. Originalni query ostaje nepromenjen. Planner pravi atomic subqueries; company/ticker/alias matching i Comparison Cues određuju opseg. Candidate pool se filtrira po ticker-u, merge/dedup radi po stabilnom ID-u, a izbor radi u rundama da svaka subquery dobije najmanje dva chunk-a. Preostala mesta popunjavaju se po RRF rezultatu i bonusu. Finalni context je najviše 10 jedinstvenih chunk-ova; balanced partial evidence se zadržava kada puna kvota ne može da stane.

Retrieval metrike

MiniLM dense, v2	300	0,5472	0,6300	0,3171	istorijski dense baseline final embedder, dense-only lexical-only corpus benchmark istorijski hybrid result in INTERNSHIP_REPORT.md
BGE-base dense, v3	300	0,7072	0,7967	0,5168	
BM25, v3	300	0,7517	0,8400	0,5428	
BGE/BM25 RRF	300	0,8117	—	0,6157	
Scope-aware hybrid	300	0,8411	—	0,6157	
Retriever-only finalization	64 scored	hit@50 0,8594	—	MRR@50 0,5051	istorijski promoted comparison; opsegaware path v1 frozen release baseline

Prve tri dense vrednosti dolaze iz data/evaluation/dense_retrieval/ i data/evaluation/bm25_retrieval/; hybrid vrednosti su sačuvane u INTERNSHIP_REPORT.md kao istorijski corpus-wide comparison i ne treba ih mešati sa 75-case end-to-end gate-om. Na Mobileye-only dense baseline-u od 60 pitanja Recall@10 je 0,6167, MRR@10 0,4446 i hit rate 0,6833. Drugi istorijski 34-question subset ima Recall@10 0,7206; drugačiji query set znači da rezultati nisu direktno zamenljivi.

Pre-balanced P0 selector je imao candidate recall 1,0, ali final recall 0,5887. Promovisana company-balanced politika je na tom frozen five-case gate-u imala candidate recall 1,0, final recall 1,0, quota satisfaction 1,0 i source-display exactness 1,0; ovo je mali P0 gate, ne corpus-wide generalizacija.

Qdrant je v19 primary storage: server 1.18.2, Python client 1.19.0, alias ava_filing_chunks_current, fizička kolekcija ava_filing_chunks_89d3a5be9e7d7a8e, 4.526 tačaka, 768 dimenzija i Dot distance. Audit je prošao. Lokalni NPZ/BM25 path ostaje fallback/shadow reproducibility oracle; pri konfigurisanom primary Qdrant kvaru readiness pada i sistem ne prelazi na mock odgovor. Qdrant parity je prihvaćen za svih 11 dense cases i tri final-selection cases u release dokumentaciji.

9. Generisanje odgovora i citiranje

src/generation/prompts.py, src/generation/service.py, src/generation/provider.py, src/generation/citations.py i src/orchestration/task_execution.py grade grounded generation. Prompt označava filing excerpts kao untrusted evidence, a short-term context i memory kao untrusted user context. Svaka factual claim treba neposredan tačan source ID u uglaste zgrade. Citation parser prihvata samo ID-eve iz finalnog generation context-a; nepostojeći, malformirani ili neupotrebljeni ID-evi se odbacuju. Ako nijedan citation ne može da se razreši, source lista je prazna.

Tabele se prosleđuju kao strukturirani headers, rows i units, a korisnički interfejs ih prikazuje iz schema-v2 podataka, ne rekonstruiše ih iz Markdown-a. Prompt razlikuje total, subtotal, procenat, period, jedinice i valutu. Evidence-derived calculations se izvode tek posle validacije operandâ; model ne bira rezultat kao autoritet. Ako deo multi-part pitanja nema dokaz, podržani deo se može odgovoriti, a nepodržani deo se eksplicitno označava kao nedostupan.

srpski generation koristi odvojeni prevodilački korak koji čuva citation ID-eve i redosled tvrdnji. U v16 language parity testu, 10 parova je imalo company resolution, route, gold recall i numerical parity 1,0; citation-ID parity je 0,8 i to je eksplicitno prihvaćen release exception.

Generation metrike i ograničenja

Oracle-context tri-run evaluacija za 75 slučajeva imala je invalid citations 0, source-display exactness 1,0 i abstention accuracy 0,9067. U realnom end-to-end v1 run-u diagnostic LLM judge (GPT-4o) na 225 records zabeležio je claim correctness 0,8133, faithfulness 0,8000, citation support 0,7956, abstention 0,7600, relevance 0,8356 i conciseness 0,8178. Judge je dijagnostički; kontrolna single-human review od 20 answer pairs dala je pass 1,0 za correctness, faithfulness, citation support, abstention i relevance, ali nije imala drugog reviewer-a i nije sertifikovala kompletne excerpts. Zato se ta dva rezultata ne spajaju u jednu "tačnost".

End-to-end latency iz v1 tri realna run-a: prosečno 3.028–4.350 ms po run-u, p95 5.490–5.732 ms, sa jednim maksimumom 93.774 ms. Gateway usage/cost nije kompletno dostupan; provider usage se beleži kada ga provider

vrati, a cenu ne izmišljamo. V19 freeze koristi Azure-compatible Chat Completions i `llm_streaming=false`; ako provider vrati samo buffered JSON, AVA šalje jedan kompletan delta, bez lažnog token-by-token kucanja.

10. Metodologija vrednovanja

Evaluacije su slojevite i koriste frozen inputs, manifest hash-eve, source commit, model, corpus/index, prompt i parametre. Phase plan zabranjuje tuning na holdout-u: development služi za prompt rad, validation za promociju, a holdout samo za završni izveštaj.

Corpus retrieval	300	dense/BM25 Recall, Hit, Complete, MRR, latency	data/evaluation/dense_retrieval/, bm25_retrieval/
QA/generation	75	kategorije: factual, synthesis, comparison, table, absent, follow-up, web	data/evaluation/finalization/v1/qa_gold.jsonl
Agent route/tool	60	route, ticker, tools, freshness, source keys	data/evaluation/finalization/v18/...
Conversation	9 turns + 4 state cases	follow-up, topic switch, recall, delete, isolation	v18/runs/conversation-history-v1
Memory	20	explicit/summary, edit, delete, relevance, ownership	v1/memory.jsonl i release runs
Security	8 direct live + dokument boundary tests	injection, prompt/ID/secret leakage	v1/runs/security-direct-live-v1
Language	10 paired prompts	resolution, route, recall, numbers, citations	v16/runs/language-parity-v1
Korisnički interfejs	43 Vitest + lint/type/build	UI/API/accessibility contracts	v19 phase6 ledger

Deterministički testovi i ljudski label-i su autoritativni za route, ownership, citations, numbers i security. LLM judge je samo dijagnostika. Za failure se prvo pita da li je dokaz retrieval-ovan; ako nije, problem je corpus/index/parser/ chunking/retrieval, a ako jeste, problem je generation/prompt/grounding.

V19 release gates: focused serverska strana 151 passed, korisnički interfejs lint passed, 43 korisnički interfejs tests passed, TypeScript passed, production build passed, 60/60 route/tool cases passed, conversation-history gate passed i freeze validation passed. V19 phase6 ledger takođe beleži raniji complete suite 446 passed, 3 skipped, 267 subtests.

11. Routing i bounded planning

Istorijski sistem je koristio više preklapajućih deterministic route checks, route LLM, retrieval planner i memory-opseg inference. To je dovodilo do gubitka jedne kompanije, odbacivanja web dela mešanog pitanja i pogrešnog calculator poziva. LLM_ROUTER.md i LLM_ROUTER_REFACTOR.md definišu finalni dizajn: jedan bounded LLM JSON planner i server-side typed validation.

Planner dobija originalni query, canonical companies/aliases, server-owned chat opseg, bounded short-term turns, validirani singular follow-up ticker, owner-opsegd memory candidates, matching upload excerpts i capability limits. Plan sadrži original query, memory references, do četiri task-a i dependencies. Task vrste uključuju filing retrieval, upload retrieval, trusted web, direct/evidence calculation, conversation i clarification.

Server pre izvršavanja proverava schema, task IDs, dependencies, ticker enum, memory ownership, source keys, URL policy, task/tool limits i ambiguity. Dozvoljene su samo uske normalizacije: jedan spoljašnji JSON Markdown fence, implicitni sec_edgar key i poznati filing-shaped current-web oblik. Server ne popravlja arbitrarne URL-ove, opseg, IDs ili budžete.

Implementirane popravke obuhvataju their/both follow-up, singular pronoun context, gubitak kompanija u comparison-u, possessive tickers, product aliases, CEO letter-count false positive, stale web fallback, upload pre-search i typed memory relationships. Mixed filing/web i filing/upload zadaci mogu se izvršavati bounded parallelism-om; calculator čeka validirane evidence dependency. Ako jedan task ne uspe, raspoloživi dokaz ostaje, a nedostajući deo se ne izmišlja.

Preostala ograničenja su planner context resolution kod nekih ambiguous follow-up upita, provider planovi koji mogu biti malformed ili over-budget i činjenica da trusted web rezultat može biti nedostupan. U tim slučajevima bezbedno odbijanje je očekivano ponašanje, ne dokaz da činjenica ne postoji.

12. Web stack i calculator

`src/tools/web_search.py` je provider-neutral adapter sa Tavily Search API-jem. Trusted source registry dozvoljava SEC, issuer official, NHTSA, exchange, Robinhood i Reuters kategorije, ali planner bira samo source keys, ne proizvoljne domene. Ticker se rešava pre query rewrite-a; market query je npr. TSLA current stock price. Result mora koristiti HTTPS i odobren host. Redirects se ne prate automatski; lokalne/private IP adrese, credentials, nebezbedni portovi i neodobreni URL-ovi se odbacuju. Excerpt je ograničen, HTML se čisti, a web tekst se tretira kao untrusted data.

Current quote zahteva kvalifikovan izvor, publisher timestamp, retrieval timestamp, market status i disclosed delay. Ako takav rezultat ne postoji, AVA kaže da verifikacija nije uspeła umesto da koristi zastareli filing ili nepovezan članak. V18 manifest: 60/60 route/tool cases, web-required recall 1,0, unnecessary web call rate 0 i calculator false positives 0; live Tavily smoke je vratio tri allowlisted Tesla investor-relations rezultata.

`src/tools/calculator.py` koristi Decimal, ograničava dužinu izraza, dubinu, broj operacija i decimalna mesta i ne izvršava Python/kod. Podržava genuine arithmetic i evidence-derived operands. Ne računa ponavljanje, enumeraciju, letter/name manipulation ili prosto prepisivanje broja. Historical Phase 10 calculator regression je 10/10, exactness 1,0, ali v19 effective configuration ga uključuje samo kada je deployment capability eksplicitno aktivirana i validirana; provider-native function calling nije potreban.

13. Istorija razgovora, upload-i i long-term memory

`src/conversations/` koristi PostgreSQL kao canonical owner-opsegd storage za tenant/user, conversations, messages, summaries, source uses, feedback, pins, company opseg, memory preferences i auth sessions. Skladište pregledača nije trust boundary. Short-term context je bounded, extractive, newest-first sa chronological restoration; aktivni turn se izuzima, oversized turn se preskače, a summary se rebuild-uje.

Long-term memory je derived semantic index u posebnom Qdrant collection-u. V19 manifest navodi top-k candidate 5, similarity threshold 0,55 i token budget 1.024. PostgreSQL je source of truth; Qdrant se sinhronizuje, a edit/delete menja oba sloja. Memory write je explicit opt-in za stabilnu preference/profile informaciju; memory ne može biti evidence za CEO, revenue, market price ili filing claim. Memory se planneru daje kao untrusted context, typed po relaciji (preferred company, favorite CEO, preferred metric itd.).

V18 conversation evaluator: query-only accuracy 0,6667, contextual accuracy 0,8889, history-dependent query-only 0,0 naspram contextual 1,0, delta 1,0; standalone contextual accuracy 0,75, topic-switch contextual accuracy 1,0, planner errors 0. Četiri state slučaja (delete conversation, delete all, cross-user isolation, cross-conversation isolation) su prošla.

Upload pipeline u `src/documents/` prihvata PDF i text, čuva originalne bytes i source text, obrađuje ih kroz owner/chat-opsegd Qdrant collection i prikazuje izvor. Upload pre-search postoji, ali relevance bridge mora biti dovoljno jak da ne preotme nepovezan filing upit. Instruction-like sentences se quarantinuju samo u provider-facing excerpt-u; originalni source ostaje nepromenjen.


Ovo je bitna hijerarhija: filing/upload/web su evidence uz provenance; memory i conversation su untrusted context; model output je niže od svih tih izvora i nikada ne postaje evidence.

14. Korisnički interfejs i korisničko iskustvo


`src/korisnički interfejs/src/App.tsx`, `src/korisnički interfejs/src/styles.css`, `src/korisnički interfejs/src/i18n.ts` i `React/TypeScript` komponente čine AVA interfejs. Podržani su responsive desktop i mobile layout, light theme sa belom pozadinom, dark theme sa vrlo tamno-plavom pozadinom, keyboard navigation, focus states, semantic controls, reduced-motion pravila i nenametljivi live status regioni. Kanonski avatar je `src/korisnički interfejs/avatar/ava.png`, a odobrene teme koriste `ava-light.png` i `ava-dark.png`; favicon je supplied `favicon.png`. AVA identitet je restriktivan i ne uvodi izmišljenu biografiju ili mascot behavior.

UI ima levi sidebar sa recent/pinned chatovima, company-opseg selector, Settings za General, Memory i Personalization, model/language izbor, upload meni za PDF i pasted text, Sources panel, citations, thinking/status evente i feedback. srpski i engleski UI strings postoje u `i18n.ts`. Assistant avatar je uz assistant poruku, ne uz user


poruku. Markdown se renderuje bez unsanitized HTML-a. Source cards imaju filing narrative/table schema, web ili upload provenance; raw internal chunk IDs nisu primarni korisnički label.



Slika 1: Prazan AVA chat pre prvog pitanja




Slika 2: Levi sidebar sa istorijom razgovora i desni sidebar sa Sources prikazom




Slika 3: Settings → General sa appearance, language i answer-model kontrolama.


Slika: kompanijski opseg i filing source prikaz u aktivnom razgovoru.




Slika 4: Settings → Memory sa uključivanjem i upravljanjem long-term memory.



Slika 5: Settings → Personalization sa kontrolama za stil odgovora.



Slika 6: Upload meni



Slika 7: Pasted-text upload dijalog sa filename poljem



Rivian's CEO is Robert J. Scaringe, identified in the latest 10-K filing as "Chief Executive Officer, Chairman of the Board of Directors" and "Principal Executive Officer."

Hide sources (1)

Rivian Automotive, Inc. (RIVN)
2025 10-K · Item 16 — Form 10-K Summary

SIGNATURES

RIVIAN AUTOMOTIVE, INC.	
By:	/s/ Robert J. Scaringe
Robert J. Scaringe	
Chief Executive Officer, Chairman of the Board of Directors	
Date: February 12, 2026	(Principal Executive Officer)

[Open SEC filing](#)

Was this answer useful?

Slika 8: Citirani filing odgovor sa odgovarajućom source karticom.



Rivian Automotive (RIVN) is at \$15.6901 per share, quoted in USD, from Robinhood. Quote timestamp: 2026-09-04 23:58:52 UTC; retrieved: 2026-09-06 17:28:46 UTC; market status: closed; delay: real time.

Hide sources (1)


RIVN Stock Price Quote & News - Rivian Automotive - Robinhood
robinhood.com · Retrieved 9/6/2026, 7:28:46 PM

Stock Snapshot Rivian Automotive(RIVN) stock is priced at \$15.69, giving the company a market capitalization of 22.79B. It carries a P/E multiple of -6.16. As of 2026-09-04, Rivian Automotive(RIVN) stock has fluctuated between \$15.56 and \$15.99. The current price stands at \$15.69, placing the stock +0.9% above today's low and -1.9% off the high. Rivian Automotive(RIVN) shares are trading with a volume of 14.13M, against a daily average of 21.58M. [...] In the last year, Rivian Automotive(RIVN) shares hit a 52-week high of \$22.69 and a 52-week low of \$12.39. In the last year, Rivian Automotive(RIVN) shares hit a 52-week high of \$22.69 and a 52-week low of \$12.39. ## RIVN News Shares of Rivian Automotive Inc. (NASDAQ:RIVN) are trading marginally lower Friday afternoon, demonstrating relative resilience compared to the broader electric... What's Going On With Rivian Stock Friday? [...] Better Stock: Lucid vs. Rivian? (Hint: Unit Economics and Gross Profits Are Key.) Key Points Rivian's RIVN price: USD 15.690100; quote timestamp: 2026-09-04T23:58:52.59756174Z; market status: closed; delay: real time


[Open web source](#)

Was this answer useful?


Slika 9: Citirani web odgovor sa publisher-om, URL-om i retrieval timestamp-om.



Slika 10: Calculator odgovor sa dokazanim računom.



Slika 11: Srpski odgovor koji zadržava citation markere.



Slika 12: Memory-resolved referenca, nakon koje se činjenica o CEO-u zasniva na filing evidence-u.



Tesla's CEO is Elon Musk, identified in the 10-K signatures as "Chief Executive Officer (Principal Executive Officer)."

Tesla (TSLA) stock price was \$352.89 per share, quoted by Robinhood; quote timestamp: 2026-09-04 23:59:58 UTC; retrieved at: 2026-09-06 18:55:03 UTC; market status: closed; delay: real time.

[View sources \(2\)](#)

Was this answer useful?

[Yes](#)

[No](#)

Slika 13: Mešoviti filing/web odgovor sa odvojenim tipovima izvora.


Dijagrami

Dijagrami su eksportovani u PNG kako bi ostali vidljivi u GitHub prikazu, PDF izvozu i Markdown rendererima bez Mermaid podrške. Ovaj izveštaj koristi srpski set dijagrama iz diagrams/.


SEC ingestion i retrieval pipeline



Slika 14: SEC ingestion i retrieval pipeline



Slika 15: Bounded planner routing



Slika 16: Evidence hierarchy and citation validation

15. Deployment, observability i security

start_app.sh pokreće lokalni PostgreSQL i Qdrant, inicijalizuje/audit-uje filing collection, čeka readiness API-ja i pokreće Vite. FastAPI je u src/serverska strana/, korisnički interfejs je Vite aplikacija, a PostgreSQL migrations su u src/conversations/migrations/. Qdrant filing collection i memory collection su odvojene. V19 readiness zahteva usklađene artifact counts i Qdrant alias.

Environment konfiguracija je serverska strana-only: SEC user agent, model provider, Tavily key, PostgreSQL DSN, Qdrant URL/alias, tenant/user boundary i tool limits. API key, gateway headers, prompt, retrieval scores, stack traces i raw provider errors ne odlaze u pregledač. /api/ready proverava stvarnu zavisnost; Qdrant kvar u primary režimu nije skriven mock fallback-om.

src/observability/request_trace.py beleži request ID, original query, resolver, subqueries, candidate provenance, quota/token allocation, final evidence, answer, citations, stage latency, time-to-first-token, provider usage, cancellation i redigovan error class. Pregledač vidi samo opaque X-Request-ID. OBSERVABILITY.md navodi retention default 30 dana za spoljašnji log sink; logovi mogu sadržati pitanja i odgovore i moraju biti access-controlled.

Security model koristi OIDC-derived tenant/user u produkciji, owner predicates u PostgreSQL-u i tenant/user Qdrant filtere. Upload limit je 20 MiB, request body limit 16 KiB, postoje rate limits, timeout-i, bounded retries i circuit

breaker. React Markdown isključuje HTML, source schemas su fixed, a citation filtering sprečava raw ID disclosure. Raw uploads ostaju zaštićeni. PostgreSQL i Qdrant nisu javno izloženi; deployment zahteva HTTPS, secure cookies, CSRF, secret rotation, backup/restore drill i image/dependency scanning.

16. Greške, debugging i popravke

td headers, pogrešni balance/year redovi	parsing	idealizovani parser	span-aware table-schema-v2 i numeric data-row heuristic	table fixture testovi; processed QA	budući filing layout-i zahtevaju proveru
Velike tabele seku se po redovima	chunking	narativni limit primenjen na tabele	jedna kompletna logical table po chunk-u	chunk QA, 965 table chunks	vrlo velike tabele imaju veći chunk
Character chunk IDs zastarevaju	evaluation	promena veličine menja sekvencijalne ID-eve	config-specific gold mape i hashes	chunk/evaluation tests	legacy rezultate treba čitati kao istorijski
MiniLM slabiji retrieval	embeddings	slabija semantička reprezentacija	BGE-base v1.5 promocija	300-case benchmark	BGE je engleski-focused
Kandidati pronađeni, ali final evidence nepravedan	selection	fixed top-10 favorizuje jednu kompaniju	balanced per-company quota i min 2/subquery	P0 candidate/final recall 1,0	quota može biti nemoguća kod malog pool-a
Fale pojedine kompanije u comparison-u	planner	više nezavisnih route/planner odluka	atomic task plan, final ticker validation	v18 60/60; v1 istorijski failures	ambiguous context može biti odbijen
their/pronoun follow-up gubi opseg	routing	query-only plan bez validiranog context-a	singular prior-answer ticker i bounded context	v18 history contextual 1,0	samo unambiguous singular reference
Super Cruise nije bio GM alias	resolution	alias coverage nije ažuriran	alias test i frozen labels	Phase 1 six-failure repair	
current request pada u filing fallback	routing	web-disabled fallback nije bio fail-closed	stale fallback fix	Phase 1; v18 web-required recall 1,0	
CEO name/letter count pokreće calculator	calculator route	keyword false positive	genuine arithmetic classifier	60 route cases; false positives 0	
Calculator je ranije bio nedostupan u frozen runtime-u	capability	fail-closed disabled config	Decimal path i explicit capability gates	istorijski 10/10 regression; v19 config	
Brave provider više nije aktivan	web	provider promenjen	direktan Tavily adapter + registry	live smoke, v18 route gate	rezultat zavisi od qualifying provider-a
web instructions mogu uticati na model	security	web tekst tretiran kao instrukcija	source quarantine, URL/domain screening	direct security 8/8 safe	
citation display je ranije vraćao previše izvora	citations	fallback na sve retrieved chunks	cited-only resolution	P0 0,4286 istorijski → v18 gate pass	
srpski citation set nije uvek identičan	localization	prevod/selection može promeniti ID set	engleski planning + citation-preserving translation	v16 citation parity 0,8	prihvaćena release exception
history-only planner ne rešava follow-up	conversation	nema prethodnog turna u query-ju	bounded recent context + extractive summary	history delta 1,0	
memory meša favorite CEO i preferred company	memory	semantički match bez typed relationship	planner memory_resolution i owner filter	v18 memory/state gate	
upload preuzima nepovezan filing upit	upload routing	nearest match bez relevance bridge-a	server-side pre-search i threshold	route manifest upload cases	
empty chats su se nepotrebno kreirale	UI/history	kreiranje pre prvog sadržaja	defer empty conversation creation	korisnički interfejs/serverska strana tests	
shared model selection je mogla da race-uje	serverska strana	self.generator.model mutacija	request-opsegd model argument	Phase 1 mutation scan zero	
runtime prompt branch je bio kontradiktoran	generation	legacy strict-abstention flag	uklonjen rejected production branch	Phase 1 tests i commit 9654d73	
provider nema native tools/strict JSON	provider	gateway capability mismatch	server-side typed executor i safe normalization	capability probes, route tests	
buffered gateway nema genuine streaming	delivery	provider vraća kompletan JSON	buffered delta, bez fake typing	SSE contract tests	

Commit history pokazuje ovu evoluciju kroz npr. 9059544 (Tavily), 97df606 (typed plans), 6073264 (settings), 1c62d8b (request model isolation), 4dc016e/7f23dde/4f62c3d (boundary refactors), ae7a7cb (memory controls), 379e877 (bounded task execution) i 56d3ae6 (pronoun follow-up fix).

17. Arhitektonske odluke i trade-off-i

SEC-hosted HTML	PDF/sekundarni sajt	canonical provenance i struktura	HTML layout je nepravilan
Immutable raw Structured blocks	overwrite latest jedan plain text	validne poredbene evaluacije section/order/table provenance	snapshot se ručno osvežava složeniji parser
Logical tables	row fragments/Markdown-only	kompletni headers, units i rows	veći tabelarni chunk
Recursive token chunks BGE-base Hybrid RRF	fixed/character chunks MiniLM dense-only	bolje semantičke granice bolji Recall/MRR lexical + semantic komplementarnost	actual overlap nije garantovan 768D i veći compute dodatni index i tuning
Qdrant	samo NPZ/FAISS	persistent filtered vector service	operativna zavisnost i parity audit
FastAPI + React	notebook/UI-only	odvojeni API i accessible pregledač UX	više deployment komponenti
PostgreSQL history Semantic memory	pregledač/local memory full transcript	server ownership i deletion preference recall uz bounded context	DB lifecycle/retention posao untrusted derived index
Decimal calculator	model arithmetic	deterministic exact result	samo allow-listed genuine arithmetic
Tavily trusted registry Bounded LLM planner	arbitrary web open-ended agent	freshness uz source controls mixed tasks uz finite execution	provider/key/result availability planner može pogrešiti ili odbiti
Server validation/ownership Evidence-first generation	korisnički interfejs assertions free-form model answer	tenant, opseg i tool safety grounding, abstention i source truth	serverska strana je složeniji veći prompt/context i latency

Agent sa otvorenim skupom akcija i Grafovski RAG su namerno odbačeni. Bounded plan je dovoljan da poveže filing, upload, web, calculator, conversation i clarification, ali ne dozvoljava proizvoljne akcije ili kod.

18. Budući planovi i moguće optimizacije

Već autorizovan budući rad treba odvojiti od spekulacije. Kandidati koji su navedeni u finalization dokumentaciji, ali nisu deo frozen release-a, uključuju:

- još bolji planner context resolution i typed memory references;
- stabilniji mixed-source filing/web planovi i jači quote provideri;
- meren cross-encoder reranking, prvo Mobileye-only, uz zaštitu BGE baseline-a;
- bolji multilingual/srpski retrieval;
- veći i nezavisniji QA/generation set, više ljudskih review-era i inter-reviewer agreement;
- concurrency-safe per-request model selection i dalju modularizaciju velikih facade modula;
- bogatiji source editing i UI polish;
- potpuni production OIDC, retention, backup/restore i horizontal rate limiting;
- filing-image ingestion, koja je u Phase 6 eksplicitno preskočena.

Ovo nisu promovisane karakteristike. Ne treba uvoditi Qdrant sparse fusion, reranker, image retrieval ili open-ended tools bez pre/post evaluacije, rollback plana i novog freeze manifest-a. Cost, token usage i provider streaming takođe treba meriti pre optimizacije; ne smeju se zaključivati iz prosečnog latency-ja.

19. Zaključak

Frozen v19 AVA release candidate pruža proverljiv RAG sistem nad 11 SEC 10-K filings: immutable acquisition, structure-preserving parser, logical-table preservation, recursive token chunking, aligned BGE embeddings, hybrid

retrieval, Qdrant persistence, bounded planning, grounded generation, citation filtering, Tavily web, Decimal calculation, owner-opsegd history, upload evidence, semantic memory i React/FastAPI interfejs.

Najčvršći rezultati su corpus reproducibility, 4.526 usklađenih chunks/vectors, Qdrant audit, 300-case retrieval gains, balanced P0 evidence selection, 60/60 v18 route/tool gate, history-dependent contextual improvement i v19 serverska strana/ korisnički interfejs release gates. Najvažnije granice su ograničena veličina evaluation setova, dijagnostički status LLM judge-a, provider-dependent web dostupnost, buffered umesto token streaming-a, prihvaćena srpski citation parity 0,8, planner ambiguity i operativna složenost velikih runtime facades.

AVA zato demonstrira inženjerski princip važniji od same fluentnosti: odgovor je koristan tek kada se može povezati sa tačnim ulazom, retrieval odlukom, validiranim dokazom, kontrolisanim alatom i bezbedno prikazanim izvorom.

Proširena tehnička razrada

Sledeće stranice predstavljaju detaljniju metodološku i implementacionu razradu prethodnih poglavlja. Sažeti deo iznad daje orijentaciju, dok ovaj deo eksplicitno razdvaja istraživačke pretpostavke, implementacione odluke, eksperimentalne rezultate, greške i granice zaključivanja. Brojevi su preuzeti iz sačuvanih artefakata; kada rezultat pripada starijem kandidatu ili manjem skupu, to je navedeno uz sam rezultat.

1A. Uvod: problem kao lanac verifikacije

Klasičan chatbot ocenjuje se uglavnom po tome da li odgovor zvuči relevantno. Za SEC analizu to nije dovoljno. Godišnji izveštaj sadrži desetine hiljada rečenica, finansijske tabele, posebne jedinice, više fiskalnih perioda i ponovljene termine. Jedna numerički uverljiva, ali pogrešno pripisana vrednost može biti ozbiljnija greška nego kratak odgovor koji otvoreno kaže da dokaz nije pronađen. Zbog toga je AVA projektovana kao lanac sa odvojenim ugovorima.

Acquisition Parsing	SEC submissions + CIK HTML snapshot	immutable HTML + metadata ordered typed blocks	form, accession, URL, hash required fields, order, provenance
Chunking	blocks + versioned config	narrative/table chunks	coverage, section, table completeness
Embedding	ordered chunks	aligned vectors + manifest	count, shape, norm, source hash
Retrieval Evidence policy	query + opseg candidates + token budget	candidates/ranks final context	Recall, Hit, MRR, gold survival quota, deduplication, token packing
Generation	original query + context	answer + citation IDs	citation resolution, support labels
Presentation	validated result	pregledač source cards	korisnički interfejs schema, no internal leakage

Ovakva dekompozicija je namerno skuplja od jedne pipeline funkcije. Dobit je u diagnostici: ako odgovor nema dokaz, moguće je pitati da li je HTML izgubljen, blok pogrešno klasifikovan, chunk izbačen, vektor neusklađen, kandidat pogrešan, evidence selector nepravedan ili je model imao dovoljan dokaz ali ga nije upotrebio. Bez te separacije svaka greška bi izgledala kao "LLM hallucination".

Druga centralna odluka je da se korisnički zahtev ne menja u transcriptu. Planner sme da napravi interni query poput TSLA current stock price, ali se originalna formulacija zadržava u PostgreSQL-u i request trace-u. Time su sačuvani audit, reprodukcija i mogućnost da se proverí da li je preformulacija promenila značenje.

Treća odluka je negativna: model nije trust boundary. Model može predložiti plan, ali ne može sam izabrati neodobreni ticker, memory ID, URL, kalkulaciju ili source. Isto važi za upload i web tekst: oni mogu sadržati instrukcije, pa se tretiraju kao podaci, nikada kao sistemske naredbe.

2A. Korpus: izbor, snapshot i statistička interpretacija

Korpus nije zamišljen kao kompletna baza svih kompanija koje razvijaju autonomna vozila. On je eksperimentalni okvir. Uključuje proizvođače vozila, dobavljače senzora, čipove i platforme sa dovoljno javnih SEC objava da se mogu postavljati pitanja na nivou poslovanja, rizika, proizvoda, finansija i uporedne analize.

Najvažnija posledica fiksnog korpusa je da “company opseg” ima formalno značenje. Ako korisnik navede Tesla, planner ne sme proizvoljno proširiti zahtev na celu industriju. Ako navede više kompanija, svaka mora preživeti plan i evidence allocation, osim ako korisnik nije postavio konfliktan ili nejasan uslov.

Snapshot metadata

company	čitljiv naziv	source label i filter
ticker	kanonski identitet	opseg, Qdrant payload, resolver
cik	SEC identitet	acquisition i validacija
form	razlikovanje 10-K/10-K/A	primary filing guard
filing_date	datum objave	provenance i prikaz
reporting_period	fiskalni period	odgovor i numerička validacija
accession_number	stabilni SEC filing identitet	URL i reproducibility
source_url	direktni izvor	source card

latest se ne čita kao promenljivi runtime rezultat. Acquisition u trenutku preuzimanja bira latest normal 10-K, ali jednom sačuvan snapshot ostaje ulaz za sve kasnije eksperimente. Kada se pojavi noviji filing, on se čuva kao novi artifact; stari se ne pregazi. To je uslov za poštene pre/post rezultate.

Zašto ne PDF kao primarni ulaz?

SEC-hosted HTML je izabran zato što ima originalne DOM odnose, Inline XBRL vidljiv tekst i direktnije source provenance. PDF bi bio koristan za vizuelnu verifikaciju i buduću image fazu, ali ekstrakcija redova, kolona i anchors iz PDF-a uvodi novi sloj grešaka. Phase 6 filing-image ingestion je eksplicitno preskočen; izveštaj ne tvrdi da AVA rešava slike ili grafikone.

3A. Autonomna vožnja kao analitički slučaj upotrebe

Autonomous-driving kompanije ne predstavljaju homogenu kategoriju. Jedna firma može prijaviti prihode po automobilskom segmentu, druga po senzorskom proizvodu, treća po data-center platformi, a četvrta uglavnom po istraživačko-razvojnoj aktivnosti. Termini kao “autonomous”, “driver assistance”, “lidar”, “EyeQ”, “vehicle platform” i “automotive” mogu pripadati različitim delovima izveštaja.

To motiviše dva tipa pitanja:

1. **Within-company:** šta kompanija tvrdi o poslovanju, proizvodima, rizicima, segmentima ili finansijskim rezultatima?
2. **Cross-company:** koje su razlike između kompanija kada se usklade period, metrika, jedinica i nivo objava?

Drugi tip zahteva više od top-1 semantic search-a. Potrebno je sačuvati company opseg, dati svakoj kompaniji dokazni budžet i sprečiti da jedan dokument popuni ceo prompt. Odatle dolaze Comparison Cues, atomic subqueries i round-robin selection.

Važno je odvojiti motivacionu hipotezu od rezultata. Projekat ne meri “rast industrije” niti tvrdi da je bilo koja kompanija najbolja. On meri kvalitet inženjerskih komponenti na frozen filing corpus-u i frozen evaluation setovima.

4A. Acquisition implementacija i operativni tok

Acquisition ima tri faze: registry resolution, SEC submission lookup i content download. Registry u src/filings/corpus.py mapira naziv/ticker/CIK. Lookup u src/filings/fetch_data.py filtrira exact 10-K, a ne fuzzy sličan form. Tek zatim se gradi archive URL za primary filing HTML.

Pre upisa se proveravaju HTTP rezultat, content bytes, očekivani filing identitet i metadata. Preprocess faza kasnije ponovo proverava usklađenost filename godine, form-a, ticker-a, CIK-a i perioda. Dvostruka validacija je namerna: acquisition greška ne sme da se pojavi tek kao neobjašnjiv retrieval pad.

fetch_data	kreira novi snapshot	ne	network/SEC/user-agent/form
process-existing	ne	kreira blocks	metadata/HTML/parser
chunk generation	ne	kreira chunks	invalid config/section
embedding	ne	kreira NPZ + manifest	model/shape/alignment
Qdrant import	ne	kreira collection	point/hash/count mismatch

Raw immutability nije ograničen na organizaciona konvencija. data/raw/ je eksperimentalni kontrolni uzorak. Ako se parser poboljša, isti bytes mogu ponovo proći kroz novi parser; ako se preuzme novi filing, to je nova verzija i nova evaluacija.

5A. DOM parser: od HTML stabla do blokova

Parser radi kao ordered traversal, a ne kao globalno sabiranje teksta. U svakoj tački traversal-a čuva se section state. Heading signal može doći iz HTML taga, bold/styled pasusa ili standardnog SEC Item izraza. Block extractor odlučuje da li je node heading, paragraph, list item ili table, a zatim emituje jedan strukturiran zapis sa source locator-om.

Zašto je redosled važan?

Ako se svi paragrafi prikupe nezavisno od tabela, tekst pre tabele može izgubiti odnos prema tabelarnom naslovu. Ako se sadržaj stranice deduplikuje globalno, ponovljeno zaglavlje može biti uklonjeno baš iz nastavka gde je potrebno za tumačenje redova. Zato je cleanup konzervativan: uklanja samo elemente za koje postoje jaki signali da nisu filing sadržaj.

Inline XBRL granica

Inline XBRL ima dve suprotne opasnosti. Uklanjanje celog wrapper-a može ukloniti vidljivi broj ili label; zadržavanje skrivenih XBRL čvorova može ubaciti tehnički sadržaj koji korisnik nikada nije video. Pravilo je: ix:hidden se uklanja, vidljivi wrapper se unwrap-uje, a vidljivi tekst ostaje. Ova odluka čuva i čitljivost i izvorni redosled.

Block contract

block_id	stabilna korelacija sa chunk-om i citation resolution
ordinal	provera document order
content_type	razlikuje narrative, list i table
section/section_path	opseg unutar filing-a
text	retrieval/generation tekst
source_tag/anchor	audit prema DOM-u
table_schema_version	kompatibilnost logical-table parsera
filing metadata	company-level provenance

Validacija odbija prazan tekst, nedostajuća polja, nekonzistentne ID-jeve i ne-serijalizabilne objekte. Output se prvo piše u privremeni fajl i tek onda promovise, čime se sprečava da čitalac vidi poluobrađen JSONL.

5B. Tabele: fizička geometrija, semantika i fallback-i

Najveća parser lekcija bila je da fizički HTML layout nije isto što i logička semantika. rowspan i colspan određuju geometriju, ali ne govore da li je red header, subtotal, balance ili podatak. Zato table-schema-v2 prvo čuva fizičko stanje, a tek zatim primenjuje heuristike i klasifikaciju.

Redosled rekonstrukcije

HTML table
 → raw cell extraction
 → span-aware rectangular grid
 → removal of only fully empty alignment lanes

- header/data boundary detection
- title/section/unit inference
- row-role and table-kind classification
- logical table + raw-cell mapping

Prazna unutrašnja ćelija se ne uklanja, jer bi se vrednost iz sledeće kolone pomakla. Globalna jedinica mixed nije poraz; ona je signal da se po kolonama moraju čuvati preciznije jedinice. Nejasna tabela se zadržava kao evidence uz fallback marker, umesto da se tiho izbací.

Konkretni failure mode-ovi

Bold td header postaje data	samo th je header	formatting + header heuristika
Beginning balance postaje header	prvi red je uvek header	prvi numerički podatkovni red
2026/2027/2028 postaju kolone	svaki numerički red je header	čtvorocifrena godina nije dovoljna
RSU naslov se gubi	neposredni tekst je generički	title candidate filtering
višeredni debt header ostaje u body	samo jedan header red	header paths i contiguous pre-data rows
mixed money/percent dobija percent	jedna globalna jedinica	column_units + mixed

QA nije zasnovan samo na lepom Markdown-u. Proverava se da su svi non-empty raw cell sadržaji mapirani, da nema standalone marker kolona, da je Markdown validan, da su headers/rows pravougaoni i da source mapping ostaje dostupan.

6A. Chunking kao eksperiment, ne kao proizvoljan parametar

Chunk size je istovremeno retrieval granularity i generation context cost. Mali chunk može preciznije pogoditi jednu tvrdnju, ali gubi prethodni naslov, jedinicu ili uslov. Veliki chunk daje više konteksta, ali otežava ranking i povećava prompt. Zbog toga je poređenje rađeno na istim ulaznim blokovima i sa istim strukturnim proverenama.

Strategija	Prednost	Mana	Odluka
Character 1.200/150	jednostavna istorijska baseline	ne odgovara model tokenima	povučena
Fixed token	precizan nominalni overlap	često seče rečenice	kandidat, nije promovisan
Recursive 250	više jedinica i granica	više chunk-ova	kandidat
Recursive 500	bolje granice, manje chunk-ova	veći pojedinačni tekst	promovisan
Table row fragments	manji retrieval units	gubi globalni table context	odbačeno
Complete logical table	čuva redove/header/units	može preći embedding limit	promovisano

U dokumentima se čuva i karakter-span i token-span. Karakter-span olakšava mapiranje nazad na tekst, a token-span omogućava proveru stvarnog overlap-a i modelskog budžeta. Section prefix ulazi u limit jer će biti prisutan u kasnijem generation context-u.

Najveća semantička odluka jeste izuzetak za tabele. Ako bi se tabela delila po 500-token limitu, pitanje “kako se total odnosi prema redovima?” moglo bi zahtevati više nezavisnih pogodaka. Jedan kompletan logical table chunk čuva taj odnos. U embedding fazi veliki table input može biti skraćen zbog modelskog maksimuma, ali source JSON i BM25 ostaju kompletni; to je svesna kombinacija, ne tvrdnja da embedding vidi sve tokene.

7A. Embedding input, poravnanje i gubitak dugih tabela

Embedding nije ograničen na `model.encode(chunk['text'])`. Za narativ je tekst direktan, ali tabela se pretvara u deterministički searchable view sa `company/ticker, section, region, title, units, header lines` i `row/value statements`. Structured table podaci se paralelno čuvaju za prikaz i exact evidence.

Manifest v3 je zaštita od tihog poravnanja. Loader proverava:

1. da chunk file hash odgovara manifestu;
2. da je redosled input hash-eva isti;
3. da NPZ count odgovara chunk count-u;
4. da je shape (n, 768);
5. da su vrednosti finite i normalizovane;

6. da model revision i prefix policy odgovaraju konfiguraciji.

Current eleven-company manifests beleže 322 table embedding input-a iznad 512-token modelskog limita, sa maksimumom pripremljenog table input-a 4.606 tokena, i nula skraćenih narativnih inputa. Stariji broj od 28 pripada ranijem desetokompanijskom snapshot-u i ne sme se koristiti za aktuelni korpus. Ovo je važna poznata slabost: dense vector može slabije predstavljati kraj veoma velike tabele. BM25 i buduća row/column retrieval strategija su prirodni pravci, ali nisu promovisani bez nove evaluacije.

8A. Retrieval: od globalnog skora do opsegaware dokaza

Dense i BM25 score nisu direktno uporedivi. Zato se ne sabiraju sirove vrednosti; RRF koristi poziciju u listi. Ako je chunk visoko u dense i BM25 rezultatima, dobija veći fused score. rrf_k kontroliše koliko se rank razlika ublažava. Promovisani runtime koristi rrf_k=100 i kandidat dubinu 50, dok istorijski corpus benchmark beleži raniju RRF konfiguraciju; zato su rezultati označeni verzijom.

Candidate recall naspram final recall

Ova razlika je presudna. Candidate recall pita: “da li je gold dokaz negde u širem pretraženom pool-u?” Final recall pita: “da li je dokaz u stvarnom promptu koji je model dobio?” U P0 eksperimentu candidate recall je bio 1,0, ali final recall 0,5887. To znači da embedding i kandidat retrieval nisu bili prvi kvar; evidence selection je izbacio dokaz.

Balanced allocation algoritam

Za svaki atomic subquery i ticker pravi se nezavisan pool. Stable ID merge čuva više provenance zapisa umesto da duplicira chunk. Selector zatim radi u rundama:

1. uzmi do dva dostupna chunk-a iz svake subquery lane;
2. ponavljaj po company/subquery lane dok postoji budžet;
3. popuni preostale slotove globalno po RRF + 0.01 bonusu;
4. dedupliciraj po stable chunk ID-u;
5. packuj kompletne chunk-ove pod generation token budget;
6. zabeleži eventualno neispunjenu kvotu u trace-u.

Algoritam ne garantuje da je svaki chunk jednako dobar. Garantuje samo policy granice i fer priliku za svaku podržanu kompaniju. Ako jedna kompanija nema dovoljno kandidata, druge ne smeju automatski pojesti ceo budžet bez zapisa o neispunjenoj kvoti.

Metrike po tipu pitanja

Saved dense summaries sadrže odvojene rezultate za single_narrative, single_table, two_chunk i three_chunk. Na BGE v3, Recall@10 je 0,7107 za single narrative, 0,7875 za single table, 0,6786 za two-chunk i 0,5402 za three-chunk pitanja. Complete@10 je odgovarajuće 0,7107, 0,7875, 0,4429 i 0,1724. Ovo pokazuje da je “hit” lakši od kompletne multi-chunk pokrivenosti i da multi-part evidence ostaje glavni retrieval izazov.

Company variance

Na BGE dense v3 Recall@10 je zavisio od kompanije: Ford 0,9556, NVIDIA 0,7389, Tesla 0,6833, Mobileye 0,6222, General Motors 0,7056, Alphabet 0,7389, Qualcomm 0,4833, Aurora 0,6611 i Ouster 0,6667; tačne vrednosti po svim kompanijama ostaju u saved summary artifact-u. Razlike ne treba interpretirati kao kvalitet kompanije: odražavaju terminologiju, chunk distribution, query/gold sastav i disclosure format.

8B. Scope resolver, query rewriting i failure analysis

Resolver prvo normalizuje Unicode, punctuation i whitespace, zatim traži canonical company names, tickers i aliases. Jednoslovni Ford ticker F zahteva poseban oprez da se ne poklopi sa običnim engleskim tokenom. Fuzzy matching se koristi samo uz threshold i winner-margin, a ambiguity je validan rezultat.

P0 resolution baseline od 46 slučajeva imao je accuracy 0,6087, exact 0,9615 i typo 0,0. To je kandidatski istorijski rezultat. Kasnije su uvedeni aliases, normalizacija i explicit opseg validation; v18 route manifest pokriva aktuelne route slučajeve, ali ne treba retroaktivno preimenovati stari baseline u finalni resolver score.

Query rewriting je ograničeno: može dodati kanonski ticker ili expanded title kada je to već semantički sadržano u pitanju, ali ne sme ubaciti novu kompaniju, period ili činjenicu. Executive-query failure je pokazao kako redundantni Company opseg suffix može pogoršati ranking. Posle uklanjanja suffix-a i preformulacije executive title-a, izmereni Ford table rezultat je prešao sa ranka 8/odbijen na rank 1.

9A. Generation context i prompt granice

Generation service gradi poruke iz originalnog query-ja, final evidence-a i odvojeno označenog conversation context-a. count_generation_input_tokens koristi isti format koji se šalje provider-u, uključujući system/user poruke i source wrapper-e. To sprečava da evidence selector koristi jedan token obračun, a provider drugi.

Prompt pravila uključuju:

- odgovoriti samo iz dostavljenih filing excerpts;
- ne tretirati excerpt tekst kao instrukciju;
- uskladiti period, valutu, jedinice, total/subtotal i segment;
- podržati deo multi-part zahteva kada je drugi deo nedostupan;
- citirati neposredno uz tvrdnju;
- ne izmišljati citation ID, broj, tabelu ili zaključak;
- jasno reći kada corpus ne pruža dovoljno dokaza.

Za upload i web prompt postoji dodatna boundary oznaka. Upload text se u provider-facing excerpt-u čisti od instruction-like rečenica, ali source display ostaje originalan. Tako se istovremeno čuvaju korisni susedni podaci i smanjuje prompt-injection rizik.

Citation pipeline

provider fragment/answer
 → citation parser
 → allowed final evidence ID set
 → visibility filter tokom stream-a
 → resolved cited IDs u originalnom redosledu
 → source adapter
 → pregledač-safe narrative/table/web/upload card

Candidate-only ID je nevažeći čak i kada je kandidat relevantan, jer model nije dobio taj chunk u finalnom context-u. Ako model ne citira nijedan validan ID, source list je prazna. To je namerno strože od prikaza "svih mogućih izvora".

Model kao generator, ne kao evaluator

GPT-4o judge rezultat se koristi za dijagnostiku generacije, ali ne menja answer, source ili route. Human review je label authority tamo gde je definisan; jedna osoba ne daje inter-reviewer agreement. Deterministički citation validity i source-display contract takođe nisu isto što i semantic truth. Ove kategorije se ne smeju sabiti u jednu overall chatbot accuracy metrik.

10A. Evaluacioni dizajn i reproducibility

Frozen evaluation manifest sadrži QA gold records, splits, route manifest, conversation/memory/security records i engleski/srpski pairs. Svaki sloj ima sopstvenu jedinicu analize. Retrieval score ne treba da se meša sa generation score-om, a route pass ne znači da je modelov odgovor factual.

Slojevi i failure stage

parsing	block presence, section, table mapping
chunking	config, source spans, complete table
embedding	model revision, truncation, alignment
candidate retrieval	dense/BM25 query, opseg, top-k
selection	company quota, dedup, token budget
planner	task schema, ticker, dependencies
tool	trusted source/calculator contract
generation	prompt, context, provider, abstention
citations	ID parse/resolution/source adaptation
UI	SSE, schema, rendering, accessibility

Holdout discipline je deo metodologije, ne samo release procedure. Prompt i policy promene su prvo proveravane na development set-u, zatim na validation gate-u; holdout se ne koristi za tuning. V19 freeze manifest zaključava code tree, artifact hashes, prompt hashes i effective runtime.

Regression test inventory

Test suite pokriva tests/test_dom_processing.py, test_table_processing.py, test_sec_table_fixtures.py, test_chunk_documents.py, test_embed_chunks.py, test_opseg_aware_retrieval.py, test_qdrant_retrieval.py, test_generation.py, test_generation_quality.py, test_llm_router.py, test_llm_router_memory.py, test_calculator.py, test_web_search.py, test_conversations.py, test_postgres_conversations.py, test_document_service.py, test_document_retrieval.py, serverska strana/API tests, korisnički interfejs App.test.tsx, language, observability, security i freeze tests.

V19 ledger beleži focused serverska strana 151 passed, korisnički interfejs 43 Vitest tests, lint, TypeScript i build passed. Stariji full-suite handoff beleži 446 passed, 3 skipped, 267 subtests. Skips su external-service integration uslovi, ne tihi pass rezultati.

11A. Od deterministic routing-a do typed planner-a

Početni dizajn je imao više mesta koja su mogla doneti odluku: deterministic router, route LLM, retrieval planner i memory opseg. Svaki je bio lokalno razuman, ali globalna kompozicija nije bila stabilna. Jedan route enum nije mogao izraziti "10-K CEO plus current price", niti "Ouster filing plus upload source".

Finalni TaskPlan je finite typed object. Sadrži schema_version, original query, memory resolution i tasks. Task ima task_id, kind, ticker opseg, internal query, dependencies i samo dozvoljene tool-specific fields. Server ne izvršava šta nije u planu i ne dopušta planneru da sam proširi plan.

Plan validation stages

provider JSON
 → narrow presentation normalization
 → typed schema validation
 → canonical ticker/opseg validation
 → ownership and memory-ID validation
 → dependency DAG validation
 → trusted source and URL validation
 → task/tool budget validation
 → bounded execution

Uvedene narrow normalizacije rešavaju provider presentation drift, ali nisu general-purpose repair. Ako provider vrati pogrešan URL, nepoznat memory ID, nevalidan ticker ili cikličnu dependency, plan se odbija. Ovo povećava broj clarification/error ishoda, ali smanjuje opasnost od implicitnog izvršavanja.

Memory reference resolution

Planner može da pročita top-k owner-opsegd memory candidate-e i da odabere reference poput preferred_company. Ne sme iz memory text-a zaključiti CEO, revenue ili price. Ako postoje "favorite CEO = X" i "preferred company = Y", to nisu automatski konfliktne company memories, jer su typed odnosi različiti.

Ova granica objašnjava zašto je memory context odvojen od evidence. Memory može odgovoriti “koja je moja preferred company?”, ali pitanje “ko je njen CEO?” mora ponovo ići u filing ili web evidence.

12A. Web bez gubitka provenance-a

Web alat nije generički pregledač. TavilyWebSearchTool dobija query, ticker opseg, trusted source keys i limit rezultata. allowed_domains_for iz source key-a izvodi konkretne hostove. Planner ne može da kaže “pretraži bilo gde”.

Source classes

sec_edgar	filings, XBRL, issuer metadata	SEC host registry
issuer_official	leadership/product/news	ticker-specific issuer domains
vehicle_regulator	recall/safety	NHTSA registry
market_primary	exchange quote/status	ticker-specific exchange
market_secondary	bounded quote corroboration	approved Robinhood path
news_independent	recent news	Reuters registry

URL sanitizer zahteva HTTPS, odbija credentials, unsafe ports, localhost, private/non-global IP adrese i ne prati redirect automatski. Response bytes, excerpt length i HTML cleaning su bounded. Web answer nosi publisher, URL, retrieved timestamp i, za quote, source-declared delay/market status.

Stari failure je bio web-disabled fallback u 10-K retrieval. To je semantički opasno: stock price ne sme biti odgovor iz poslednjeg annual report-a samo zato što provider nije konfigurisan. V19 routing path tu grešku tretira kao unavailable web evidence i ne tvrdi da je filing dovoljan.

Calculator evidence protocol

Calculator ima dve ulazne klase. Kod direct_calculation, svi operandi su u upitu. Kod evidence_calculation, filing/upload retrieval prvo mora vratiti cited operands, a tek onda server parsira plain decimal vrednosti, proverava jedinice/period i izvršava Decimal expression. Model ne šalje proizvoljan Python izraz.

False positives su bili jednako važni kao true positives. “Repeat Elon Musk ten times”, broj slova u CEO imenu ili lista od deset stavki nisu aritmetika. Phase 10 regression beleži exactness 1,0 na 10 slučajeva; route manifest beleži zero calculator false positives. Calculator i dalje zavisi od effective deployment configuration, pa istorijski disabled runs ne smeju biti preimenovani u failure računanja.

13A. Conversation context, upload ownership i deletion

PostgreSQL je canonical jer relational model prirodno čuva redosled, ownership, source-use i deletion audit. Qdrant memory je derived semantic index; njegov point-count ili similarity ne određuje da li poruka pripada korisniku.

Short-term context algorithm

Context builder:

1. učitava server-selected conversation turns;
2. formira complete-turn grupe;
3. izuzima aktivni turn;
4. računa o200k_base token budget;
5. bira newest-first uz skip oversized turn-a;
6. vraća izabrane turnove u chronological order;
7. dodaje extractive summary ako ulazi u limit;
8. označava sve kao untrusted context.

Ovaj proces nije query rewrite u smislu menjanja korisničkog pitanja. Njegova uloga je da planner razume “it”, “both”, “return to the first comparison” kada je to bezbedno. Ako kontekst nije dovoljan, clarification je bolji od izmišljene kompanije.

Memory lifecycle

explicit save	canonical item	upsert derived point	opt-in
chat-triggered save	validated stable preference	sync point	opt-in
edit	update source	replace point	Settings
delete one	delete/audit	delete point	Settings
delete all	cascade/audit	owner-filtered delete	Settings
reconciliation	enumerate canonical	rebuild owner index	operator job

Threshold 0,55 i candidate-k 5 smanjuju slučajno ubacivanje memory text-a, ali nisu dokaz semantic correctness. Zato se score, memory ID i selected reference beleže u serverska strana trace-u, ne prikazuju se kao filing source.

Uploads imaju dodatni chat opseg. Dokument ne sme postati vidljiv drugom korisniku ili drugom razgovoru zato što je semantic embedding sličan. DocumentIndex primenjuje owner/chat filter, a service čuva bytes, extraction status, filename, chunk ordinals i deletion lifecycle. PDF/text extraction je ograničen na podržane MIME tipove i upload-size budget.

14A. Korisnički interfejs kao security-aware adapter

Korisnički interfejs arhitektura nije ograničen na vizuelni sloj. API response modeli eksplicitno razlikuju narrative source i structured table source. Narrative source prikazuje tekst i filing/web metadata; table source prikazuje validated headers, rows i units. Ako tabela ne može da zadovolji pravougaoni schema contract, UI je ne rekonstruiše iz Markdown-a.

SSE lifecycle je:

POST /api/chat/stream

→ delta fragments

→ sources exactly after resolution

→ done

error može zameniti normalan završetak. Status/thinking događaji su UI-only aktivnosti i ne smeju se pretvoriti u provider error ili izložiti raw trace. Assistant avatar se renderuje uz assistant poruke; user poruka nema AVA avatar. Prvi non-empty fragment uklanja waiting bubble.

Light/dark CSS koristi semantic variables, fokus prstenove i responsive breakpoint pravila. Wide tables imaju horizontal scrolling. react-markdown je podešen bez unsanitized HTML-a. src/korisnički interfejs/src/i18n.ts ima engleski/srpski strings, ali semantički source labels i serverska strana ownership ostaju server-referentni.

UI testovi proveravaju API normalizaciju, cited/uncited source display, table rendering, empty-chat ponašanje, settings, sidebar, upload flow i language. V19 phase ledger beleži 43 korisnički interfejs tests passed, lint passed, TypeScript passed i production build passed. Screenshot-i nisu kreirani u repozitorijumu; zato su u izveštaju placeholders, a ne lažne reference na postojeće slike.

15A. Runtime lifecycle, readiness i observability

Startup u real mode-u učitava i validira svih jedanaest chunk fajlova i aligned BGE NPZ artifacts, normalizuje embedding matrix, gradi in-memory BM25 i učitava query embedder. Qdrant se ne rebuild-uje po request-u. Kada je Qdrant primary ili shadow konfigurisan, alias i point count moraju odgovarati frozen manifestu.

Readiness i liveness imaju različite funkcije. Liveness govori da proces postoji; readiness govori da su corpus, index i obavezne zavisnosti spremne. Stari bug je bio test koji je čitao developer .env i nije bio hermetičan. Phase 1 je uveo typed settings i test izolaciju, a v19 runtime freeze čuva effective configuration.

Request trace je oblik evidence-chain audit-a, ne analytics event za pregledač. On može povezati query → resolver → subqueries → candidates → final IDs → prompt usage → generated answer → citations → displayed sources. OBSERVABILITY.md navodi p50/p95 stage, first-token i complete latency agregaciju, provider tokens, error/cancellation rates i concurrency procenu.

Security controls imaju defense-in-depth karakter:

prompt injection	untrusted labels + quarantine	model i dalje može pogrešiti
cross-owner leak	PostgreSQL predicates + Qdrant filters	claim configuration je critical
XSS	escaped Markdown + no raw HTML	external links napuštaju AVA
resource exhaustion	body/query/evidence/tool/time budgets	per-process limits nisu globalni
secret leakage	serverska strana-only env + safe errors	logs zahtevaju access control
incomplete deletion	derived-first delete + reconciliation	nema distributed transaction

16A. Hronologija razvojnih korekcija

Git istorija pokazuje da su važni napreci uglavnom došli iz failure diagnosis-a, a ne iz dodavanja još jednog modela. 3899940 arhivirao je superseded planove; 4dc016e, 7f23dde, 8d1c063 i 4f62c3d podelili su generation, pipeline, handlers i serverska strana routes. To je smanjilo rizik da test importuje compatibility facade dok runtime koristi drugu logiku.

9059544 zamenio je Brave direktnim Tavily adapterom. 97df606 uveo je typed plan validation. af926d3 i d7accb1 popravili su web instruction quarantine i cancellation pre izvršenja. 6cef175 odbacio je repetition calculator routes, 19eab34 vratio resolved product questions u filing path, a a401492 rešio possessive tickers.

U Phase 7 nizu, c88488f je uskladio explicit memory saves, aeba7cb dodao owner memory control/provenance, 379e877 aktivirao bounded task execution, 8b46695 normalizovao bezbedne provider planove, a 56d3ae6 popravio unambiguous pronoun follow-ups. Poslednji commit za report cut je cce57af (exclude raw HTML from language stats); v19 frozen artifact ostaje vezan za source commit eksplicitno naveden u manifestu.

17A. Trade-off analiza kroz merljive posledice

Nijedna glavna odluka nije besplatna. Kompletne tabele čuvaju semantiku, ali su duže. Balanced selection čuva fer company coverage, ali povećava retrieval i generation context. BGE poboljšava ranking, ali je veći od MiniLM-a. Qdrant daje persistent filtered index, ali zahteva service readiness, snapshot, alias i parity procedure.

MiniLM → BGE	Recall@10 0,5472 → 0,7072	veća dimenzija/compute
BGE → hybrid RRF	Recall@10 do 0,8117	BM25 index i fusion
hybrid → opsegaware	istorijski Recall@10 0,8411	company/query policy
fixed selector → balanced	final recall 0,5887 → 1,0 na P0	p50 ~530 ms → ~1.345 ms
row table fragments → complete table	multi-row context	table embedding truncation risk
free fallback → cited-only	source-display exactness 0,4286 → 1,0	prazna source lista kada citation ne resolve
strict absence candidate → default	bolja abstention isolated	completeness, numeric i latency regresije

Tabela ne predstavlja apples-to-apples jednu jedinu eksperimentalnu seriju; rezultati pripadaju artifact-ima različitih faza i svaki je označen statusom. To je razlog što report čuva istorijski baseline umesto da prikazuje samo najbolji broj.

18A. Budući rad: kriterijum za promociju

Buduća optimizacija mora imati četiri elementa pre promocije:

1. precizno definisan failure koji rešava;
2. razvojni skup i nezavisan validation/holdout protokol;
3. before/after metrike po relevantnim kategorijama;
4. rollback artifact i updated freeze manifest.

Za reranking to znači da BGE-only rezultat ostaje baseline, candidate depth se povećava, cross-encoder ocenjuje query/chunk parove, a porede se Recall@k, MRR, table/narrative/multi-chunk i latency. Za multilingual retrieval treba proveriti ne samo preveden odgovor već company resolution, gold chunk recall, numeric value parity i citation-ID parity. Za memory treba meriti recall@k, precision, stale/ deleted retrieval zero-rate i owner isolation.

Ne treba uvoditi “better model” samo zato što je fluentniji. Ako model poveća judge score, ali smanji citation recall, numerical correctness ili source exactness, candidate ostaje neprihvaćen. Phase 10 strict-abstention experiment je upravo primer takvog odbijanja.

19A. Zaključna sinteza

AVA je rezultat koordinacije informacionog retrieval sistema i aplikacionog security/ownership sistema. Ključni doprinos nije ograničen na BGE embedding niti UI, nego formalizovanje granica između: šta je izvor, šta je candidate, šta ulazi u prompt, šta je memory, šta je alat, šta je citation i šta korisnik sme da vidi.

Na nivou podataka, raw HTML ostaje proverljiv, tables nisu žrtvovane radi jednostavnosti, a chunk/embedding manifesti čuvaju reproducibility. Na nivou retrieval-a, dense i lexical signal se kombinuju bez sabiranja neuporedivih score-ova, a company opseg se ne gubi u finalnom context-u. Na nivou generation-a, model dobija strukturiran dokaz, a source panel prikazuje samo ono što je model zaista citirao. Na nivou aplikacije, planner je bounded, tools su typed, memory je owner-opsegd i korisnički interfejs nije trust boundary.

Ovaj dizajn ne uklanja sve greške. On omogućava da se greška lokalizuje, izmeri, sačuva kao istorijski rezultat i ispravi bez skrivanja regresije. To je standard koji je najvažniji za tehnički odbranljiv RAG sistem nad finansijskim dokumentima.

Dodatak A — reprodukcija i čitanje artefakata

A.1. Autoritet dokumenata

Za aktivno ponašanje redosled autoriteta je: v19 freeze manifest i njegovi phase results; aktuelni source code i tests; FINALIZATION.md; zatim current deployment/security/observability dokumentacija. INTERNSHIP_REPORT.md je vredan istorijski tehnički zapis i čuva eksperimente, ali se stariji rezultati ne preimenuju u v19 metrike.

docs/archive/2026-09-pre-finalization/ sadrži deprecated plans, roadmap-e, implementation prompts i ranije deployment/architecture kopije. Oni objašnjavaju razvoj, ali nisu source of truth za frozen behavior. CLEANING_AND_CHUNKING_REPORT_FINAL.md je poseban autoritativni izvor za parsing, tables, chunking i overlap, čak i kada se stara terminologija u drugim dokumentima razlikuje.

A.2. Minimalni pregled pre novog eksperimenta

input hash	da li su isti raw/processed/chunk files?
schema	da li evaluator očekuje table-v2/chunk-v3?
model revision	da li su query/document prefixes isti?
index	da li su count, dimension, alias i point IDs isti?
labels	da li gold IDs pripadaju toj chunk konfiguraciji?
opseg	da li se koristi global, company ili planner path?
generation	da li je evidence fixed, oracle ili real retrieval?
judge	da li je diagnostic ili human-referentni?
runtime	da li su web, calculator, memory i uploads enabled?
status	da li je rezultat baseline, candidate, promoted ili frozen?

Bez ove tabele lako je porediti Mobileye-only dense baseline sa corpus-wide hybridom ili disabled-calculator end-to-end run sa enabled route manifestom.

A.3. Reprodukcion komande

```
# acquisition and processing
.venv/bin/python -m src.filings.fetch_data
.venv/bin/python -m src.filings.preprocess_filing mobileye
```

```
# current chunk and embedding path
.venv/bin/python -m src.chunking.chunk_documents mobileye --overwrite
```

```
.venv/bin/python -m src.embeddings.embed_chunks mobileye --device cpu
```

```
# audits
```

```
.venv/bin/python -m src.filings.audit_tables --strict
```

```
.venv/bin/python -m src.embeddings.audit_embeddings --strict
```

```
# serverska strana regression suite
```

```
.venv/bin/python -m unittest discover -s tests -v
```

```
# application
```

```
./start_app.sh
```

Tačni datumi, commit-i, hashes, model revision, Qdrant versions, prompt hashes, tool limits i effective settings za frozen v19 nisu implicitni u komandi; nalaze se u data/evaluation/finalization/v19/freeze_manifest.json.

A.4. Interpretacija glavnih rezultata

Recall nije correctness odgovora. Candidate recall nije final evidence recall. Source-display exactness nije semantic entailment. LLM judge score nije reviewed human truth. Latency sa jednim provider outlier-om nije SLO. Calculator exactness na 10 slučajeva nije dokaz za proizvoljnu aritmetiku. srpski citation parity 0,8 nije contradiction sa numerical parity 1,0; to su različite metrike.

Ovo razdvajanje je metodološki uslov za fer zaključak. AVA je dobro proverljiv pipeline sa jasno dokumentovanim prednostima, ali ne treba ga predstavljati kao univerzalno tačan finansijski analitički sistem.

Dodatak B — detaljna interpretacija sistema

B.1. Kako čitati AVA kao istraživački sistem

AVA nije jedan model, već kompozicija pet različitih vrsta stanja: immutable filing state, derived retrieval state, request state, owner state i presentation state. Filing state potiče iz SEC-a i mora ostati stabilan. Retrieval state čine chunk-ovi, vektori, BM25 indeks i Qdrant payload. Request state obuhvata query, plan, candidates, final evidence, tool records i answer. Owner state sadrži conversation, memory i uploads. Presentation state obuhvata SSE status, UI tema, otvorene source cards i lokalni transient prikaz.

Ova podela objašnjava nekoliko neintuitivnih pravila. Qdrant filing point nije isto što i user memory point, iako su oba vektori. A citation ID nije isto što i interni chunk ID: prvi je modelov validated reference, drugi je serverska strana korelacioni identitet. A conversation summary nije fact table; ona je kompresovan korisnički kontekst koji može pomoći planneru, ali ne može override-ovati SEC evidence.

Raw filing	SEC snapshot	ne	link/provenance
Processed block/chunk	local release artifact	ne	indirektno kroz source
Filing vector	Qdrant/index	ne tokom chat request-a	ne direktno
Query/plan/trace	server request	da	samo safe status
Conversation	PostgreSQL owner	da	da, kroz sidebar
Long-term memory	PostgreSQL + Qdrant	samo uz policy	da, kroz Settings
Upload	owner/chat service	da	da, kao upload source
Model output	provider + server	da	da, posle filtering-a

B.2. Zašto je failure-first razvoj bio neophodan

Rani razvoj je pokazao da "answer quality" može sakriti više različitih kvarova. Ako model kaže da ne zna podatak, uzrok može biti da je podatak stvarno odsutan, da je tabela izgubljena u parseru, da je tabela prisutna ali embedding skraćen, da je kandidat retrieval nije vratio, da je selector izbacio kandidat ili da je model zanemario dokaz. Svaki slučaj ima drugačiji fix.

model abstain-uje	retrieval/generation	promena system prompt-a	proveriti raw → block → chunk → candidate → final
pogrešna kompanija	resolver/planner	dodati još aliasa naslepo	proveriti exact/fuzzy/margin i opseg
citation postoji ali source nije relevantan	generation/citations	prikazati sve retrieved izvore	proveriti allowed final ID intersection
tabela izgleda prazno	parser/korisnički interfejs	parsirati Markdown u pregledaču	proveriti schema-v2 headers/rows/units
current answer koristi 10-K	routing	povećati top-k filings	proveriti freshness route i web availability
memory utiče na fact claim	context boundary	ukloniti svu memoriju	typed reference + evidence hierarchy

Ovakav triage je razlog zbog kog report čuva candidate recall i final recall odvojeno, kao i route manifest, generation-quality run i UI contract. Jedan overall score bi sakrio najvažniji podatak: gde sistem prvi put prestaje da ima dovoljno informacija.

B.3. Kontrola promena i kompatibilnost schema

Schema version nije dokumentaciona dekoracija. table_schema_version=2 označava da table chunk sadrži logical headers/rows/units i raw mapping. chunk-schema-v3 označava trenutni chunk identity/provenance ugovor. Embedding manifest-v3 zna kojim redom su chunk-ovi kodirani. Qdrant artifact version zna koji corpus snapshot je importovan. Promena bilo kog od ova tri nivoa mora promeniti hash ili release manifest.

parser header heuristic	promena block/chunk sadržaja	regenerate processed, chunks, embeddings
chunk size/overlap	novi chunk IDs i gold mapa	new config-specific evaluation
embedding revision	novi vectors i ranking	new manifests, index, retrieval run
RRF/candidate policy	promena final evidence	selection/e2e regression
prompt	promena claim/citation behavior	generation and citation run
planner schema	promena route/tool execution	route manifest and security run
migration	promena ownership/history	DB isolation and deletion tests

Release validator odbija dirty worktree, post-freeze source changes, input hash promene i Qdrant mismatch. To sprečava čestu grešku u RAG projektima: izmeriti novi rezultat na novom corpus-u, a zatim ga prijaviti kao model improvement.

B.4. Kvalitativna analiza snaga i slabosti

Ključna prednost sistema je sledljivost. Za svaki zahtev mogu se rekonstruisati originalno pitanje, odluka rezolvera, potupiti, kandidati, odabrani dokazi, korišćenje provajdera, generisani citati i prikazane kartice izvora. Tabele se čuvaju kao celina, pa se finansijski odgovor ne svodi na nepovezane ćelije. Vlasništvo nad razgovorima i memorijom proverava se na serverskoj strani.

Glavno ograničenje je složenost sistema. Moduli src/orchestration/executor.py, raniji src/backend/pipeline.py i src/generation/rag.py objedinjavali su veliki broj odgovornosti. Refaktorisanje je razdvojilo rukovaoce, servise, provajdere, planiranje i rute, ali kompatibilni fasadni moduli i dalje povećavaju složenost održavanja. Dodatno ograničenje su manji skupovi vrednovanja usmereni na pojedinačne zadatke. V18 skup od 60 slučajeva potvrđuje pokrivene obrasce rutiranja, ali ne dokazuje uspešnost za sve jezike i oblike dopunskih pitanja. Ponašanje aktuelne veb-pretrage i strimovanja zavisi od provajdera i ne može se u potpunosti zaključiti iz lokalnih jediničnih testova.